

Baseline → Final, all five benchmarks
(hollow = baseline, filled = final)

GPT-4.1 Mini
AIME
GPT-4o-mini

+6.6

-3.3

GPT-4.1 Mini
PUPA (composite)
GPT-4o-mini

+12.5

+11.4

GPT-4.1 Mini
IFBench
GPT-4o-mini

+23.8

-2.4

GPT-4.1 Mini
Hearsay
GPT-4o-mini

+2.1

-2.0

GPT-4.1 Mini
MMLU (macro)
GPT-4o-mini

+2.3

+2.1

0 20 40 60 80 100

Accuracy / composite score (%)
Net improvement Net regression